北京理工大學
BEIJING INSTITUTE OF TECHNOLOGY

2026

德以明理·学以精工

基于无人机的复杂场景中车牌识别方法研究

Dr. Yujie Fang (方宇杰)
TA：Junming Wu (吴浚铭)

BIT

北京理工大学

2026年07月

学习目标

认识数据

理解CCPD2019与CCPD2020的目录、划分和标注

读懂论文

掌握RPnet检测—识别一体化的基本思想

判断方法

能根据模糊、光照、倾斜、天气选择处理策略

启动实践

完成实验与PPT汇报

CCPD（Chinese City Parking Dataset）是一个面向中国车牌检测与识别任务的大型开源数据集

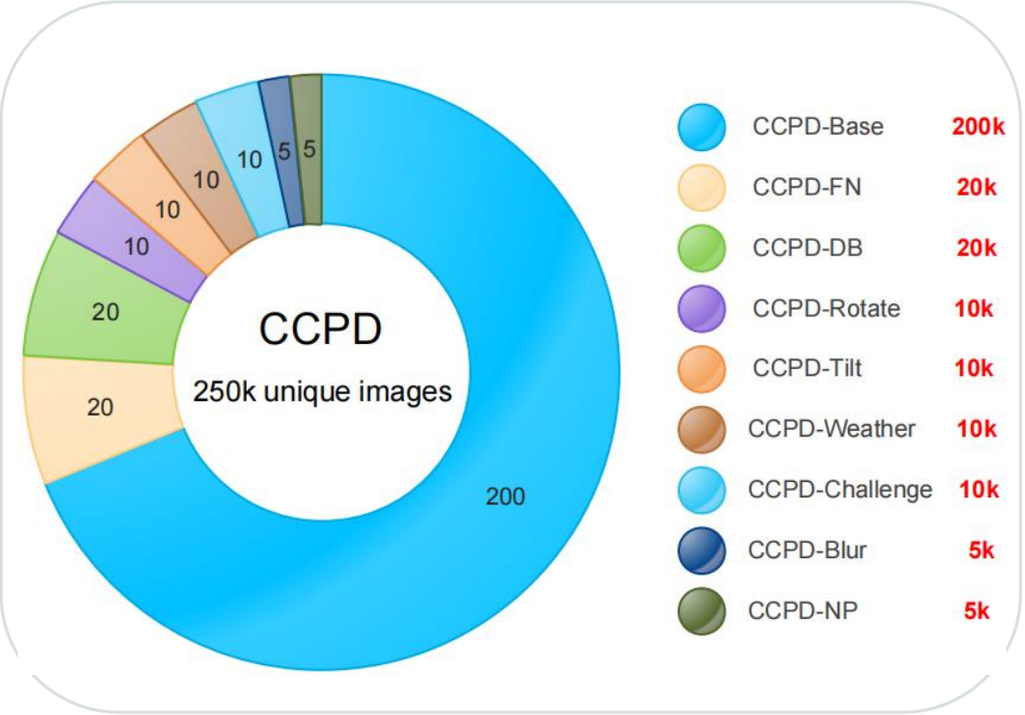
典型问题

- 公开车牌数据集规模通常较小，复杂场景覆盖不足
- 不同论文使用不同私有数据，结果难以公平比较
- 真实道路中存在距离、角度、模糊、光照和天气变化
- 检测框、角点和字符标注往往不同时具备

CCPD数据集

- 真实城市停车巡检采集，而非实验室摆拍
- 大规模、多类别、统一分辨率的中国车牌图像
- 单张图像同时提供车牌号、检测框和四角点
- 为检测、识别、矫正和困难场景鲁棒性提供统一基准

CCPD：CCPD2019与CCPD2020



约25万张图像

2018 **ECCV论文**
约25万张，8类困难场景

2019 **CCPD2019更新**
超过30万张，困难子集与标注扩充

2020 **CCPD-Green**
增加8位新能源绿色车牌

CCPD2019 包含约 34 万张车牌图像，按场景分为 9 个子集

子集	图像数	主要用途
ccpd_base	199,996	基础样本：多角度、多距离、多光照条件下拍摄
ccpd_blur	20,611	模糊样本：运动模糊或对焦失败导致的车牌模糊
ccpd_challenge	50,003	最难识别样本：综合多种干扰因素的极端困难案例
ccpd_db	10,132	光照异常：车牌区域过暗或过曝（极端亮度）
ccpd_fn	20,967	焦距异常：拍摄距离过远或过近导致的车牌畸变
ccpd_np	3,036	水平大倾斜：车牌在水平方向有较大旋转角度
ccpd_rotate	10,053	综合倾斜：水平+垂直方向均存在较大倾斜角度
ccpd_tilt	30,216	雨天样本：雨滴遮挡、反光、光线散射等干扰
ccpd_weather	9,999	无车牌负样本：包含车辆但无可见车牌（用于检测）

文件名==标注：七个字段

Area	Tilt	BBox	Vertices	Plate	Brightness	Score
面积比例	倾斜原始值	检测框	四角点	车牌编码	亮度	清晰/模糊分数

`Area - Tilt - BBox - Vertices - PlateNumber - Brightness - Blurriness.jpg`

示例：`025-95_113-154&383_386&473-386&473_177&454_154&383_363&402-0_0_22_27_27_33_16-37-15.jpg`

提示：加载数据时只需解析文件名即可获取全部标注，无需额外读取标注文件

标注字段详解

Area（车牌区域占比）

· 编码：车牌面积 / 整图面积 x 10^6 后取整
· 示例：025 → 面积比 = 25/10^6
· 值很小，因为车牌在图像中占比通常不大

Tilt Degree（倾斜度）

· 格式：水平倾斜度 _ 垂直倾斜度
· 两个角度值描述车牌平面相对相机的倾斜
· 值越大 → 车牌形变越严重 → 识别难度越高

Bounding Box（水平边界框）

· 格式：左上x&左上y_右下x&右下y
· 示例：154&383_386&473
· 左上顶点 (154, 383)
· 右下顶点 (386, 473)
· 用途：目标检测训练的定位标签

Four Vertices（四顶点坐标）

· 格式：4 组 x&y 坐标，用 _ 连接
· 起点为右下顶点，逆时针排列：
右下 → 左下 → 左上 → 右上
· 示例：386&473_177&454_154&383_363&402
· 用途：精确车牌矫正与透视变换

标注字段详解

License Plate Number（车牌号码）

格式：7 个数字索引，用 _ 分隔

对应关系：省份索引 _ 城市字母索引 _ 后5位字符索引

字符集映射：

省份（31个）：皖、沪、津、渝、冀、晋、蒙、辽、吉、黑、
苏、浙、京、闽、赣、鲁、豫、鄂、湘、粤、
桂、琼、川、贵、云、藏、陕、甘、青、宁、新

城市字母（24个）：A-Z（不含 I、O）

后5位（34个）：数字 0-9 + 字母 A-Z

示例解码：0_0_22_27_27_33_16

0 → 皖（安徽） 0 → A（合肥） 22 → E 27 → P 27 → P 33 → W 16 → P

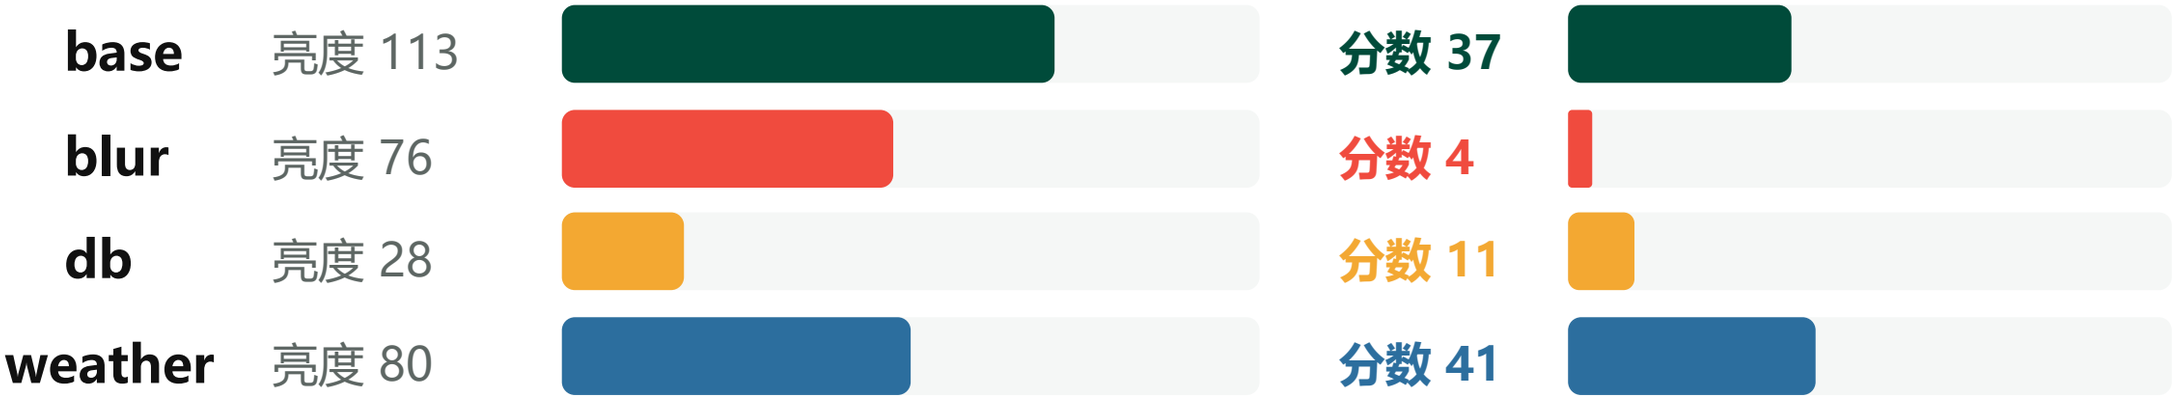
标注字段详解

Brightness（亮度）

- 取值范围：0 ~ 255
- 越小越暗，越大越亮
- ccpd_db 子集中通常处于两端（极暗或极亮）
- 可按亮度筛选样本训练

Blurriness（模糊度）

- 取值范围：0 ~ 255
- 越大表示越模糊
- ccpd_blur 子集中该值通常较大
- 可用于评估去模糊算法的效果
- 两个指标均为定量属性

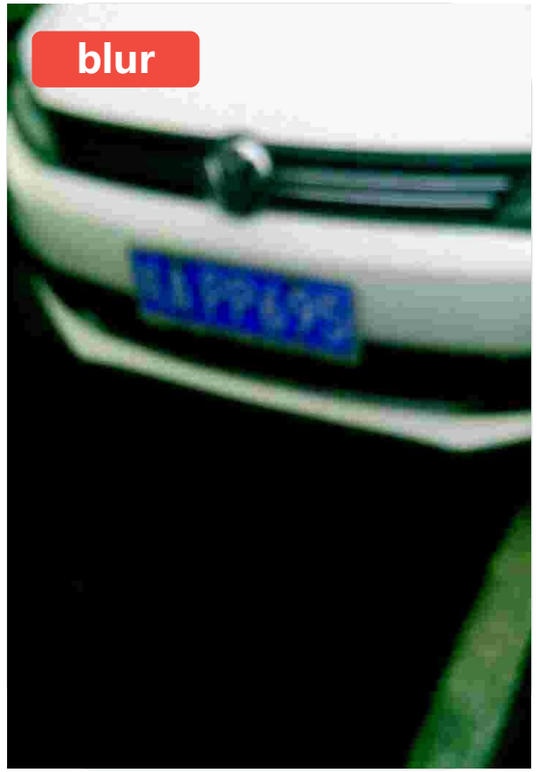


提示： Brightness + Blurriness 为定量指标，可按难度阈值筛选样本，构建分层训练集

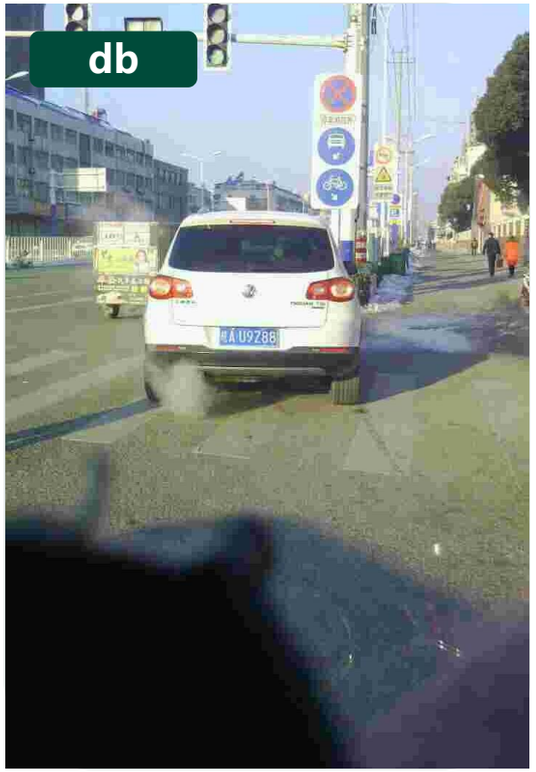
四类基础样例：同一任务，不同难度



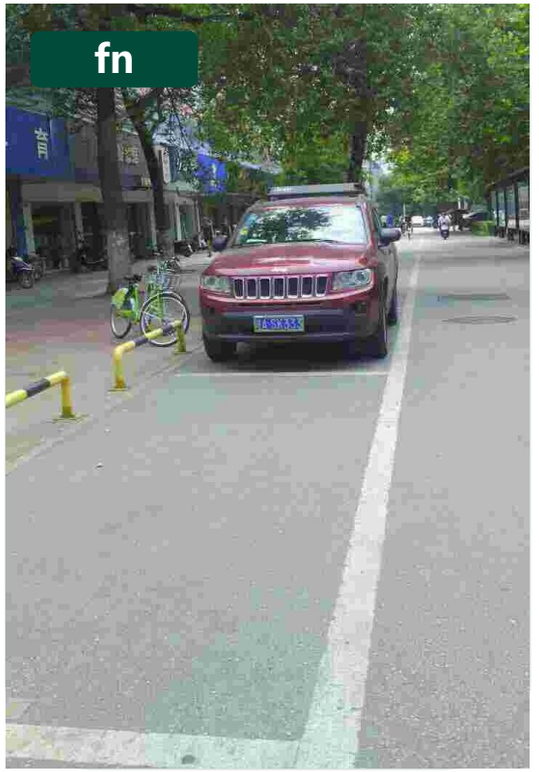
常规场景



运动/失焦模糊



暗光或过曝



远近距离变化

CCPD2019官方划分：训练、验证与困难测试



划分规则

train/val来自ccpd_base；test包含blur、challenge、db、fn、rotate、tilt。weather与np需要单独建立测试清单。

数据增强策略

几何变换

· 随机裁剪/缩放（模拟距离）

· 随机旋转/透视变换（模拟倾斜）

· 水平翻转（增加多样性）

· 仿射变换（模拟视角变化）

颜色/光照变换

· 随机亮度/对比度调整

· Gamma变换（模拟曝光）

· 高斯噪声（模拟低光照）

· 色彩抖动（Color Jitter）

模糊与遮挡

· 随机高斯模糊/运动模糊

· 随机遮挡（Cutout）

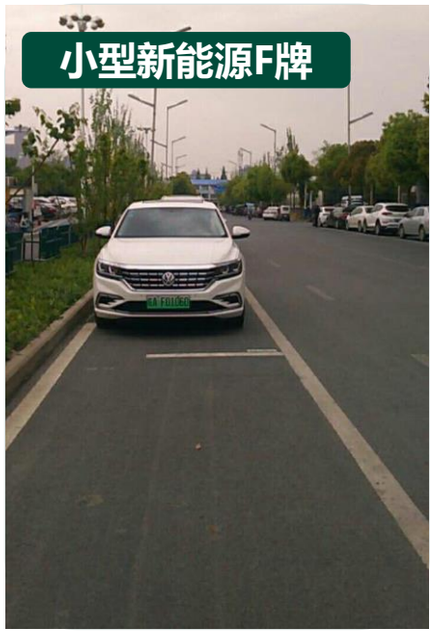
· Random Erasing

· Mixup / CutMix 混合

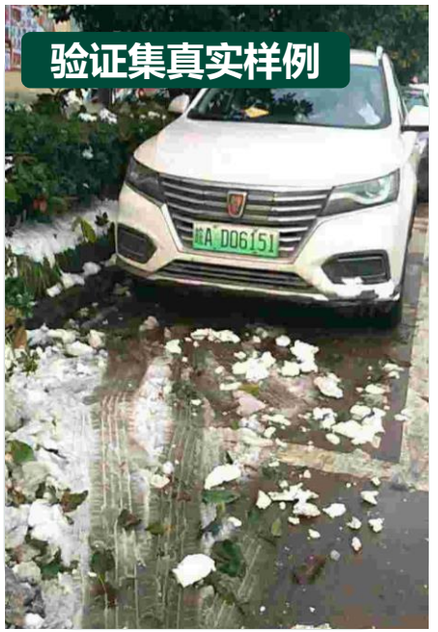
提示：增强策略应与训练目标匹配：训练去模糊模型时不应对清晰样本加模糊；测试集增强需固定随机种子

CCPD2020（CCPD-Green）：新能源车牌扩展









数据定位
补充新能源绿色车牌与8字符格式

数据集大小
11,776张；全部720×1160
JPG

数据集划分
train 5,769 · val 1,001 · test 5,006

CCPD2019 vs CCPD2020

比较项	CCPD2019	CCPD2020 / Green
主要车牌	蓝牌为主	新能源绿色车牌
字符长度	7字符	8字符
组织方式	9个场景子集 + txt划分	train/val/test
教学重点	复杂环境、检测与七位识别	颜色/格式域迁移与八位识别
模型适配	固定7位可直接训练	需8位或多头识别注意力

小型新能源示例
0_0_3_24_28_24_31_33 → 皖AD04079

大型新能源示例
0_0_24_33_30_31_24_3 → 皖A09670D

课堂提醒
检测权重可迁移；识别头必须适配8字符。蓝牌/绿牌可分开报告。

CCPD数据集的原始论文解决了什么?

1. 大数据集

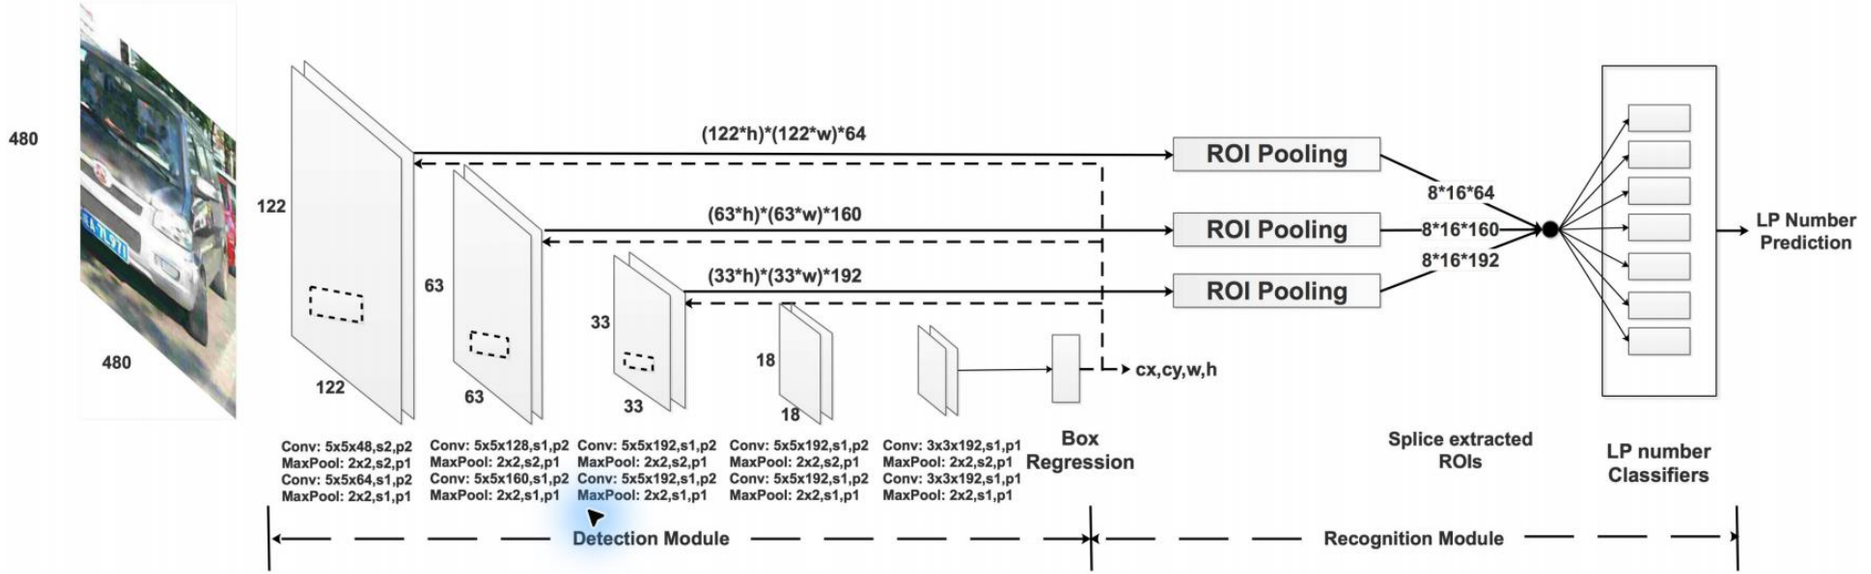
发布大规模、真实、多样的中国车牌基准

2. 统一网络

单次前向同时输出车牌框和7位车牌号

3. 速度与精度

共享特征；论文报告约61 FPS与95.5%识别精度



RPNet网络输入480×480 RGB图像 → 10层卷积 → 车牌框回归 → 多层ROI Pooling → 7个字符分类器

检测分支：十层卷积与车牌框回归



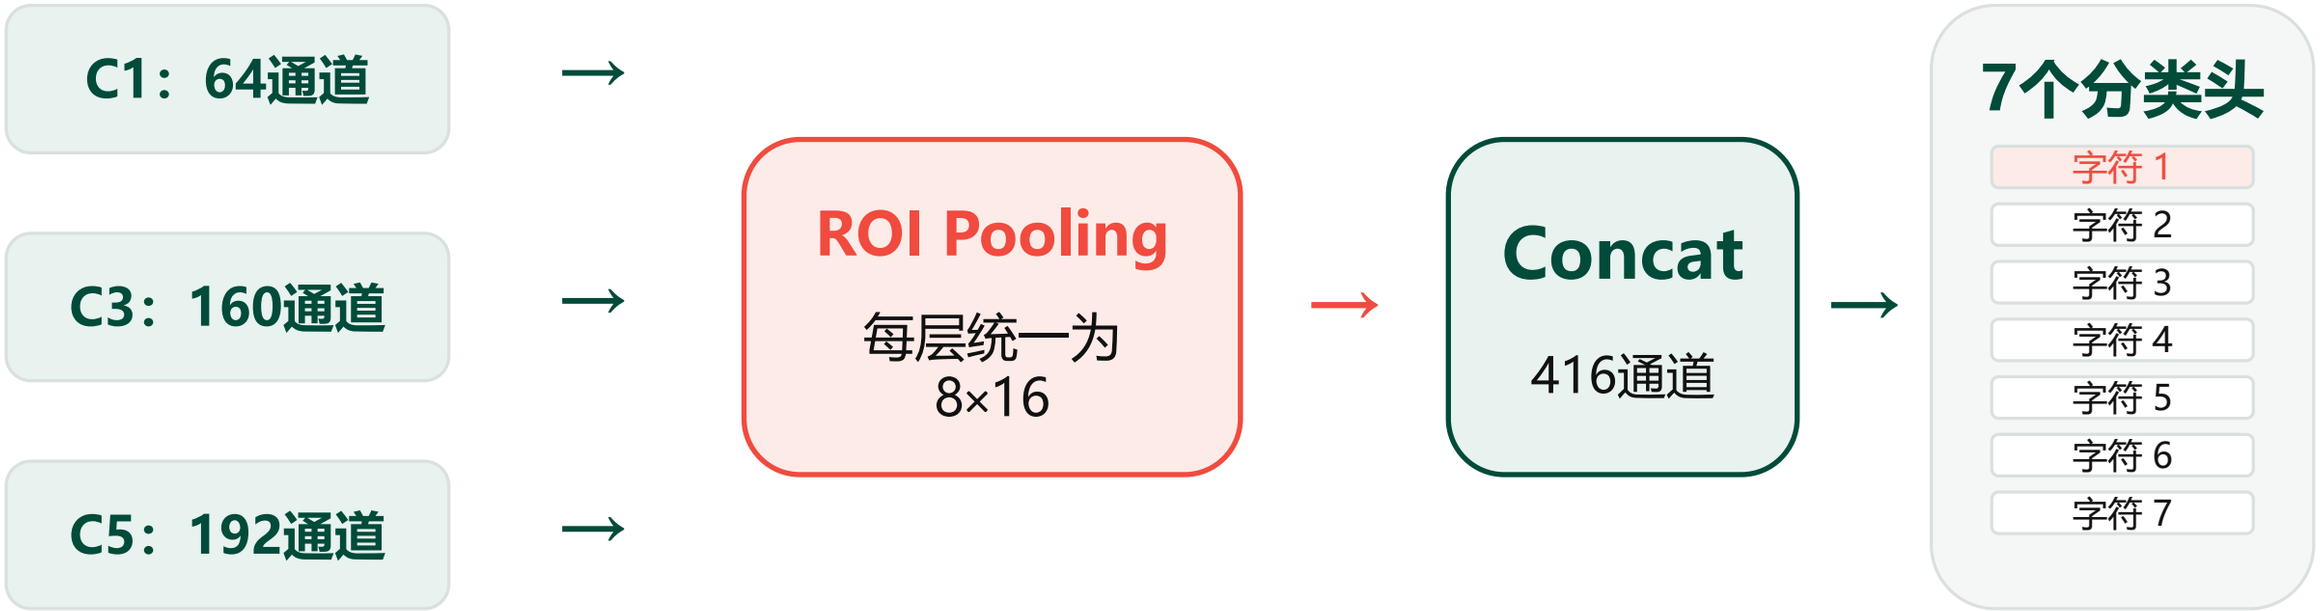
输出参数

归一化车牌框：(cx, cy, w, h)，取值约束在0—1。

检测损失

预测框与真实框使用Smooth L1损失；论文先单独预训练定位分支，使ROI在联合训练前可用。

识别分支：多层ROI Pooling + 七个分类器



注意：这一固定7槽识别头不能直接用于CCPD2020的8字符绿牌。

联合损失与训练步骤

定位损失

L_loc = Σ smoothL1(p_b − g_b)

针对 (cx, cy, w, h)

识别损失

L_cls = Σ CE(p_i, g_i)

7个字符分别计算交叉熵

$$L_total = (L_loc + L_cls) / N$$

① 从CCPD随机初始化检测模块

② 先训练定位，使预测框成为有效ROI

③ 加入7字符分类头端到端联合优化

论文结果：检测与识别兼顾速度

Towards End-to-End License Plate Detection and Recognition 11

	FPS	AP	Base(100k)	DB	FN	Rotate	Tilt	Weather	Challenge
Cascade classifier[45]	32	47.2	55.4	49.2	52.7	0.4	0.6	51.5	27.5
SSD300[30]	40	94.4	99.1	89.2	84.7	**95.6**	**94.9**	83.4	**93.1**
YOLO9000[32]	42	93.1	98.8	89.6	77.3	93.3	91.8	84.2	88.6
Faster-RCNN[29]	15	92.9	98.1	92.1	83.7	91.8	89.4	81.8	83.9
TE2E[12]	3	94.2	98.5	91.7	83.8	95.1	94.5	83.6	93.1
RPnet	**61**	**94.5**	**99.3**	**89.5**	**85.3**	94.7	93.2	**84.1**	92.8

Table 4：检测结果

12 Z. Xu et al.

	FPS	AP	Base(100k)	DB	FN	Rotate	Tilt	Weather	Challenge
Cascade classifier + HC	29	58.9	69.7	67.2	69.7	0.1	3.1	52.3	30.9
SSD300 + HC	35	95.2	98.3	96.6	**95.9**	88.4	91.5	87.3	83.8
YOLO9000 + HC	36	93.7	98.1	96.0	88.2	84.5	88.5	87.0	80.5
Faster-RCNN+ HC	13	92.8	97.2	94.4	90.9	82.9	87.3	85.5	76.3
TE2E	3	94.4	97.8	94.8	94.5	87.9	92.1	86.8	81.2

Table 5：识别结果

61 FPS

论文在Quadro P4000上的RPnet速度

94.5%

检测平均精度

95.5%

整牌识别精度

RPnet在真实复杂样本上的结果



观察结果

- 同一网络同时画出检测框并输出字符
- 可处理旋转、模糊、反光和小目标样本
- 失败仍集中在极端天气和综合困难场景

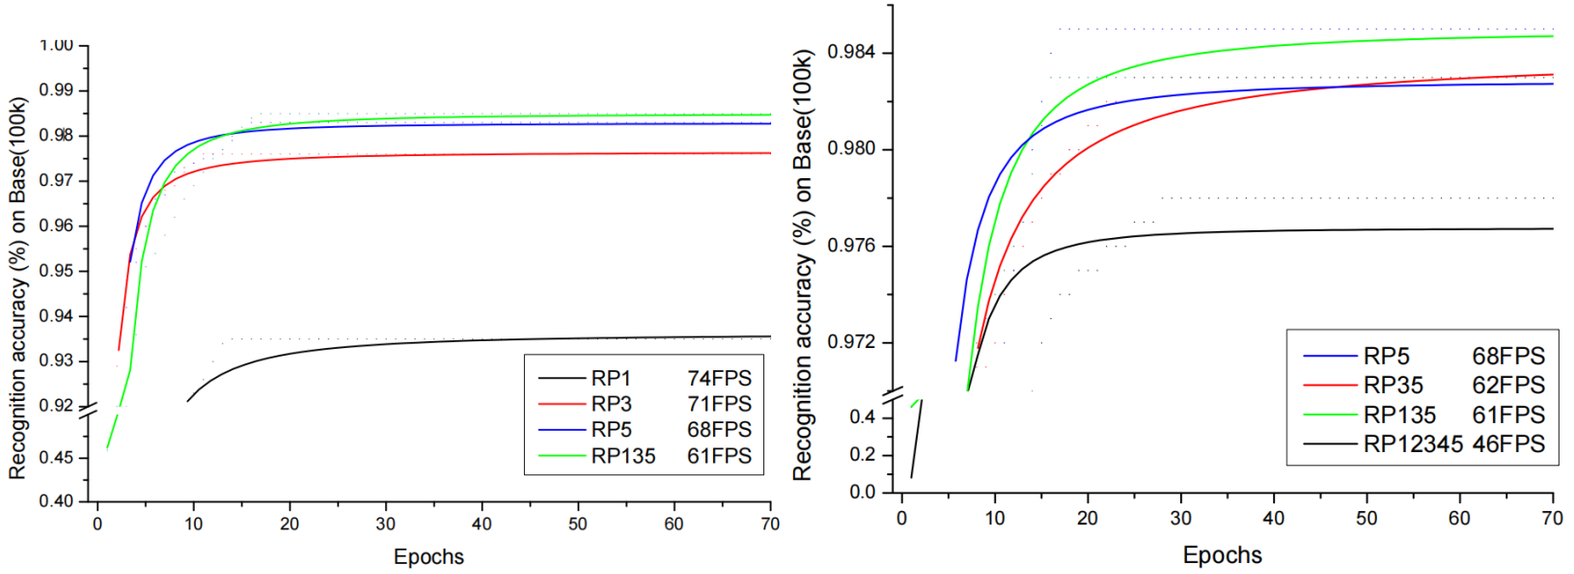
课堂问题

框稍微小一点，为什么有时反而更利于识别？

提示：检测IoU最优与识别特征最优并不完全相同。

Xu et al., ECCV 2018, Fig.4

消融实验：特征层越多不一定越好



结论一

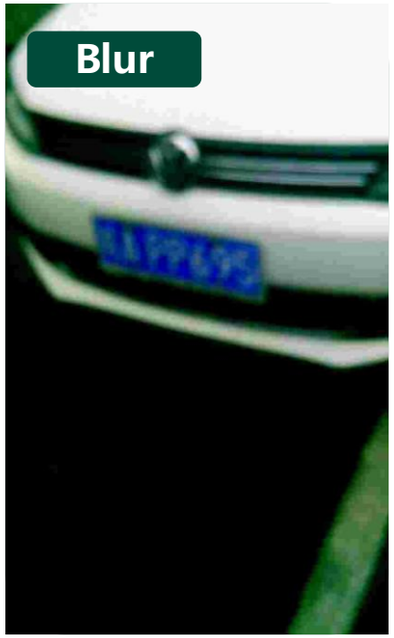
只用较浅层C1时准确率最低；较高层C5已能达到接近多层融合的效果。

结论二

从RP5到RP135略有提升；继续加入更多层RP12345反而更慢且准确率下降。

模型设计不是“堆得越多越好”：信息层级、参数容量和速度需要共同平衡。

RPnet已经能识别，为什么还需要重建?



笔画边缘丢失



遮挡与反光



多退化叠加

识别模型的边界

- RPnet负责定位和识别，并不恢复退化图像
- 模糊或遮挡会让字符判别信息直接消失
- 在极端模糊、天气干扰和多退化叠加样本中仍可能失败
- 第二部分：让输入或特征更易识别

网络结构优化不能凭空恢复已经丢失的字符笔画。

CCPD中的四类复杂退化



模糊

blur

$y = h * x + n$



光照

db

$y = \alpha x + n$



几何

rotate / tilt

$y = T(x) + n$



天气

weather

$y = D_w(x) + n$

FN反映距离与尺度；Challenge是多退化叠加；NP是检测负样本；
Weather不在当前官方test.txt中。

复杂环境的统一退化模型

$$y = D(x; \theta) + n \quad \rightarrow \quad \hat{x} = R(y)$$

x：理想清晰图

希望估计或保留的字符信息

D：退化算子

模糊核、光照衰减、几何变换

n：噪声

传感器噪声、量化噪声

y：实际观测图

无人机或巡检设备采集结果

重建是病态逆问题：只能估计和模型理解，不能保证找回已丢失的真实笔画。

增强、重建与识别导向重建

概念	目标	判断标准	主要风险
图像增强	改善亮度、对比度或边缘	人眼更容易观察	可能放大噪声或制造伪影
图像重建	估计退化前的清晰图像	有参考图时比较PSNR/SSIM	需要配对或退化模型
识别导向重建	保留字符判别信息	整牌/字符准确率提高	视觉效果不一定最漂亮

最重要的提醒

GAN或超分辨率可能生成并不存在的笔画。车牌中一个笔画的幻觉就可能把3变成8、E变成F；重建输出也不能直接当作新的真实标签。

通常先定位与几何归一化

车辆图像
720×1160
→
车牌定位
BBox / 检测器
→
四点矫正
Homography
→
退化处理
只选一种方法
→
车牌识别
预训练模型
→
结果评价
准确率 + 速度

为什么几何优先?

倾斜同时改变字符形状与空间位置。先按四角点矫正，再做亮度或清晰度处理。

一次只改变一种策略

允许多阶段处理，但要逐步消融；否则会累积伪影，也无法判断哪一步有效。

识别专项实验可使用GT框/四角点；整链路评估必须使用检测器预测结果，并将两者分开报告。

不同CCPD子集的方法示例

子集	主要问题	入门方法	可选深度方法
ccpd_blur	运动/失焦模糊	锐化、Wiener（需PSF）	预训练去模糊网络
ccpd_db	过暗、过曝、反光	Gamma、CLAHE处理暗光	低照度增强；饱和过曝单报
ccpd_fn	小目标、尺度变化	尺度归一、双三次插值	小尺度车牌可选轻量SR
ccpd_rotate	平面旋转	角度估计 + 仿射旋转	旋转检测/校正模型
ccpd_tilt	透视畸变	四点单应性变换	几何校正网络
ccpd_weather	雨雪、雾、反光	按具体天气选择方法	对应预训练恢复模型
ccpd_challenge	多种退化叠加	不单独拟合	作为综合测试集

课堂原则：先建立简单可解释的基线，再比较一个预训练深度模型。

传统方法与深度方法怎么选

传统方法

- Gamma / CLAHE：光照增强
- Wiener / 锐化：清晰度与去模糊基线（Wiener需PSF）
- 仿射 / Homography：几何矫正
- 优点：快速、可解释、容易调试

预训练深度模型

- CNN：去噪、去模糊和超分基线
- GAN：纹理更丰富，但可能产生字符幻觉
- Transformer / 扩散：效果强但计算量更大
- 优点：适应复杂退化；代价是资源和部署成本

传统先验
Gamma / Wiener
→
CNN
SRCNN / DnCNN
→
GAN
SRGAN / DeblurGAN
→
新架构
Transformer / Diffusion

本次课堂：传统方法做基线；深度模型需说明权重来源与训练域，并验证是否真正提高OCR。

重建与识别的三种组合方案

方案一：串联式

- 模块独立，容易调试
- 可直接复用预训练模型
- 本次课堂推荐

退化图 → 重建/增强 → 识别

方案二：联合训练

- 重建过程面向识别目标
- 训练更复杂，需要平衡损失
- 作为原理理解

可微串联/共享特征 + 联合损失

方案三：特征级增强

- 可设计得较轻量
- 不产生图像级伪影
- 适合后续研究或部署

不输出重建图，直接增强中间特征

实践采用方案一：先做可解释的串联基线，再比较增强与微调效果。

实验：三组对比 + 绿牌选做

实验组	图像/数据处理	模型状态	回答的问题
Baseline	无	预训练权重	原始困难样本能识别多少?
实验A	一种增强或矫正	不微调	处理本身是否有效?
实验B	同一种处理	微调识别模型/识别头	识别微调能否进一步提高?
选做C	CCPD2020绿牌	适配8字符后微调	蓝牌权重能否迁移到绿牌?

控制变量
固定网络、初始权重、裁剪方式、输入尺寸与测试集

训练处理一致
实验B的训练、验证使用相同处理；可增设“原图 + 微调”控制组。

测试规范
测试集只做确定性预处理，不使用随机增强。

实践任务原则上在课堂时间内完成

完成后提交

- 可运行代码、环境配置与数据清单
- 测试集选出的最佳模型权重
- 汇报PPT

第7日下午PPT汇报｜每人约15分钟
(讲解10—12分钟＋提问3—5分钟)